Основы анализа данных

Преобразование и объединение таблиц

Сводки, ключи и проверка соединения

Таблицы и смысл строки

Записи, справочник и сводка имеют разные строки

Таблица	Одна строка	Строк
decisions	Ипотечная запись	6830
organizations	Организация в году	470
outcome_counts	Организация, год, исход	500

Ноутбук: B02

Длинная и широкая сводка

Длинная: исходы в строках
Широкая: исходы в столбцах

Форма	Представление условного примера
Длинная	Три строки: 1 → 5; 2 → 1; 3 → 2
Широкая	Выдач 5; одобрений без принятия 1; отказов 2

Счётчики по организации и исходу

groupby разбивает записи на группы

size считает строки каждой группы

```
keys_long = ["lei", "activity_year", "action_taken"]
long = decisions.groupby(keys_long).size().rename("n")
long = long.reset_index()
```

Ноутбук: B04

Исходы в отдельных столбцах

Три счётчика исходов в строке организации

issued / approved_not_accepted / denied

```
wide_input = pd.read_csv(
    LOCAL / "outcome_wide.csv", dtype={"lei": "string"}
)
wide_input.head(4)
```

Ноутбук: B05

Разворот через pivot

index задаёт строки, columns — столбцы

values указывает, что записать в ячейки

```
wide = long.pivot(
    index=["lei", "activity_year"],
    columns="action_taken", values="n"
)
```

Ноутбук: B06

Когда для ячейки есть два значения

pivot сообщает о неоднозначной ячейке

pivot_table применяет указанное правило агрегации

```
wrong_wide = replayed_long.pivot_table(
    index=["lei", "activity_year"], columns="action_taken",
    values="n", aggfunc="sum", fill_value=0
)
```

Ноутбук: B07

Обратный разворот через melt

Поля организации остаются на месте

Названия столбцов исходов становятся значениями

```
restored = wide_input.melt(
    id_vars=["lei", "activity_year"],
    value_vars=outcome_columns,
    var_name="outcome", value_name="n"
)
```

Ноутбук: B08

Ноль отсутствующего исхода

Нет записей с таким исходом → счётчик 0

Неизвестный доход остаётся пропуском

```
wide_complete = wide.reindex(columns=[1, 2, 3])
wide_complete = wide_complete.fillna(0).astype("int64")
```

Ноутбук: B09

Проверка обратного преобразования

Сравниваем одинаковые поля в одинаковом порядке

```
expected = long.sort_values(keys_long).reset_index(drop=True)
actual = roundtrip.sort_values(keys_long).reset_index(drop=True)
assert_frame_equal(actual, expected)
```

Ноутбук: B10

Ключ справочника

lei + activity_year находят организацию в нужном году

Поле	Назначение
lei	Код организации
activity_year	Отчётный год
organization_name	Название для отчёта
source_count	Счётчик другого отбора источника

Ноутбук: B11

Сколько совпадений ожидаем

Одна запись слева → одна организация справа

Связь	Ключ слева	Ключ справа
Один к одному	Уникален	Уникален
Многие к одному	Может повторяться	Уникален
Многие ко многим	Повторяется	Повторяется

Соединение на двух записях

lei = 549300AG64NHILB7ZP05; activity_year = 2023
Две исходные записи получают одно справочное имя

source_row	action_taken	Добавленное имя
7593	1	LOANDEPOT.COM, LLC
7596	1	LOANDEPOT.COM, LLC

Ноутбук: B13

left и inner при неполном справочнике

left оставляет все левые записи

inner оставляет записи с найденным соответствием

```
left_partial = decisions.merge(
    partial_orgs, on=org_keys, how="left",
    validate="many_to_one", indicator=True
)
```

Ноутбук: B14

Полное соединение и проверка строк

on — поля поиска; how — состав результата

validate — связь; indicator — наличие совпадения

```
enriched = decisions.merge(
    organizations, on=org_keys, how="left",
    validate="many_to_one", indicator=True
)
```

Ноутбук: B15

Повтор справочника умножает строки

Повторим первую организацию в учебной копии
Её 25 записей получат по два совпадения

Справочник	Строк результата	Повторные source_row
Полный исходный	6830	0
Учебная копия с повтором	6855	25

Ноутбук: B16

Каким записям не нашлось имени

both — совпадение найдено

left_only — запись сохранилась без соответствия

```
enriched["_merge"].value_counts(dropna=False)
left_partial.loc[left_partial["_merge"].eq("left_only")]
```

Ноутбук: B17

Пропуски в ключе

Перед merge проверяем известность полей ключа

```
unknown_left["lei"] = pd.NA
unknown_right["lei"] = pd.NA
null_pairs = unknown_left.merge(
    unknown_right, on=org_keys, how="inner"
)
```

Ноутбук: B18

Какие поля брать из справочника

Для отчёта нужны ключ и organization_name

```
name_lookup = organizations[
    org_keys + ["organization_name"]
].copy()
```

Ноутбук: B19

Профиль организаций с именами

Одобрения организации / все её решения

```
profile["approval_rate"] = (
    profile["n_approved"] / profile["n_decisions"]
)
```

Ноутбук: B20

Разбор неверного соединения

Было 6830 записей, после добавления имени стало 6855

Практика преобразования и JOIN

Разворот сводки, соединение, проверка результата