Итоговый проект по анализу данных

Методичка для студентов

Исследуйте один вопрос на реальных ипотечных данных и покажите, как другой человек сможет повторить ваш расчёт. Проект можно выполнить индивидуально или в команде из 3–4 человек.

Зачем нужен проект

За семестр вы пройдёте путь аналитика от вопроса и проверки исходной таблицы до обоснованного вывода. Сохраните код и данные так, чтобы проверяющий мог заново получить число из отчёта и понять, к каким записям оно относится.

С каких данных начать

Общий источник — decisions.csv из репозитория курса. В нём 6 830 опубликованных записей HMDA о покупке жилья в округе Колумбия за 2023 год. У всех команд есть этот снимок. Для своего вопроса вы выбираете поля и группы, с которыми будете работать.

Поле	Что означает
source_row	Технический номер строки исходного снимка.
lei	Код финансовой организации.
action_taken	1 — кредит выдан, 2 — одобрение без принятия, 3 — отказ.
loan_amount	Опубликованная сумма кредита или запрошенная сумма, в USD.
income	Годовой доход в тысячах USD. Пропуски учитывайте отдельно.

Что сделать на старте

На P05 разбейтесь на пары и заполните один на двоих шаблон предложения из занятия 4. Укажите вопрос, целевую аудиторию, участников и роли, файл и поля, смысл строки, правила отбора, формулу показателя, ограничение и первый шаг. Обменяйтесь предложениями и внесите одно уточнение после обсуждения.

Для доли отказов среди записей с исходами 1–3 числитель — записи с кодом 3, знаменатель — все записи с этими исходами в выбранной группе. Чтобы проверить выполнимость темы, посчитайте размер каждой группы и число пропусков в нужных полях.

Возможные аналитические вопросы

Выберите один основной вопрос или предложите свой. Все примеры ниже можно начать с decisions.csv. Пороги 20 и 50 решений служат примером проверки чувствительности.

Исходы и организации

1. Как различается доля отказов между организациями с хотя бы 20 решениями в этом срезе?
2. Как меняется список организаций с наибольшей долей отказов при повышении порога с 20 до 50 решений?
3. Какая доля одобренных заявок заканчивается выдачей и как эта доля различается между организациями?
4. Как средняя доля отказов по организациям соотносится с долей по всем записям? Какую роль играет размер групп?
5. Какая часть решений и какая часть отказов приходится на десять организаций с наибольшим числом записей?

Сумма кредита и доход

6. Как различаются медиана и разброс суммы кредита между выдачами, одобрениями без принятия и отказами?
7. Как меняется доля отказов по диапазонам суммы кредита?
8. Как различается доля отказов по группам дохода среди записей с известным доходом?
9. Сохраняются ли различия в доле отказов между группами дохода внутри одного диапазона сумм кредита?
10. Как доля одобрений без принятия среди всех одобрений различается по диапазонам сумм кредита?

Пропуски и устойчивость выводов

11. В каких организациях доход отсутствует чаще и на скольких записях основано сравнение?
12. Как доля пропусков дохода различается между выдачами, одобрениями без принятия и отказами?
13. Как меняется общая доля отказов при переходе от всех записей к записям с известным доходом?
14. В каких организациях доля отказов сильнее всего меняется после исключения пропусков дохода и сколько записей исключено?

Роли и вклад участников

Распределите работу по ожидаемым результатам. Например, команда сравнивает доли отказов по организациям и проверяет, как вывод зависит от минимального размера группы.

Роль	Задача и результат на примере
Подготовка данных	Проверяет ключи, отбор и пропуски. Сохраняет карточку данных и таблицу с количеством решений по организациям.
Анализ	Считает доли отказов. Сохраняет числители, знаменатели и сравнение при порогах в 20 и 50 решений.
Визуализация и интерпретация	Строит график долей с размерами групп. Пишет вывод и указывает, как состав заявок ограничивает сравнение.
Воспроизводимость и проверка	Запускает проект с чистого ядра, пересчитывает долю для одной организации и сверяет её с графиком и отчётом. Сохраняет инструкцию запуска.

В предложении запишите для каждого участника имя, конкретную задачу и файл или расчёт, который он подготовит. В команде из трёх можно объединить визуализацию и интерпретацию с анализом. При индивидуальной работе выполните все четыре вида задач в рамках одного показателя и одного среза.

Как показать свой вклад

В contributions.md укажите, что вы сделали, где это можно увидеть и как проверили результат. В команде каждый участник проверяет один шаг коллеги и готов объяснить основной вывод. При индивидуальной работе покажите собственную проверку и рецензию, которую дали другому проекту на P15.

Что спросить у другой команды

- Какие поля нужны для ответа и есть ли они в таблице?
- Что считается одной записью и какие записи входят в знаменатель?
- Сколько записей в каждой группе и изменится ли вывод при другом отборе?
- Где в коде получено число на графике и как его повторить?

От первого расчёта до защиты

На практике используйте метод лекции в своём репозитории. Сохраняйте код, таблицу или график вместе с короткой проверкой. На следующей паре берите результаты предыдущего этапа.

Когда	Что подготовить
P05 · Занятие 4	Одно описание на пару с вопросом, источником, показателем и первым шагом.
P06–P07	Первую сводку и график. К P07 добавьте исходный снимок, манифест, карточку данных и журнал качества.
P08–P10	Проверку устойчивости, сравнения и гипотезу. К P10 оформите раздел исследования с ограничениями.
P11–P14	SQL-запросы и проверки. К P14 подготовьте полный черновик. При использовании ML добавьте baseline и независимую проверку.
P15–P16	На P15 воспроизведите результат другой команды или участника и внесите исправления в свой проект. На P16 защитите итог и личный вклад.

Что сдавать в конце

- Репозиторий с README, версиями зависимостей, исходными данными, карточкой данных и запускаемым кодом.
- Минимум два сравнения или диагностических шага и три графика, связанные с вопросом. Покажите чувствительность хотя бы к одному обоснованному решению анализа.
- Отчёт на 5–8 страниц без приложений и презентацию на 6–10 слайдов. Укажите метод, результат, альтернативное объяснение, ограничение и следующий шаг.
- Запись о вкладе, рецензию, ответ на неё и перечень проверенных исправлений.

Как оценивается проект

Проект составляет 40% оценки курса. Из 100 баллов проекта 10 отведено вопросу, 20 данным, 25 анализу, 15 выводам, 15 воспроизводимости и 15 личному вкладу. Описательный анализ подходит для итогового проекта. Если используете модель, приложите baseline, схему проверки и разбор ошибок.